

Masking peri-lesional na classificação de nódulos em ultrassom de mama

Plano de execução — Iniciação Científica, 1 mês Alvo: artigo curto em congresso de IA (BRACIS / ENIAC / SIBGRAPI-Workshops / CBIS)

1. A ideia em um parágrafo

Quando se recorta o nódulo de uma imagem de ultrassom para classificar benigno × maligno, joga-se fora tudo que está em volta. Só que, em ultrassom, o "em volta" carrega diagnóstico: sombra acústica posterior (sugere malignidade), reforço acústico posterior (sugere benignidade), halo ecogênico, distorção do tecido adjacente. Este trabalho testa uma alternativa simples: em vez de **apagar** o contexto, **atenuá-lo** — deixá-lo presente, porém menos saliente. A pergunta é se isso preserva sinal diagnóstico que o recorte binário destrói.

2. Hipóteses

Declarar isto **antes** de rodar qualquer experimento é o que separa um estudo de uma grade de experimentos. Com hipótese definida a priori, até um resultado negativo é publicável.

H1 — Principal (confirmatória)

Atenuar o contexto peri-lesional (*soft masking*) preserva informação diagnóstica que removê-lo (*hard masking*) destrói, resultando em AUC superior.

- **Métrica primária:** AUC-ROC
- **Comparação primária:** melhor *soft masking* × *hard masking*, na ResNet-50, na validação cruzada do BUS-BRA
- **Uma única comparação confirmatória.** Todo o resto é secundário ou exploratório, e será declarado como tal.

H2 — Secundária (arquitetura)

O ganho do soft masking deve ser **maior em CNNs do que em transformers**, porque a self-attention já aprende a reponderar regiões espacialmente. Um viés espacial explícito na entrada seria, em parte, redundante.

Se o efeito desaparecer no Swin/ViT (são modelos Transformer mais adequados que o DETR) e persistir na ResNet-50, isso é o achado mais interessante do artigo.

3. Dados

Treino e validação cruzada — BUS-BRA

Imagens	1.875
Pacientes	1.064
Scanners	4 (INCA / Rio de Janeiro)
Rótulos	Comprovados por biópsia — 722 benignos, 342 malignos
Anotações extras	BI-RADS 2–5, máscaras de lesão
Splits	Partições oficiais por paciente

Três motivos pelos quais este é o dataset de treino, e não o BUSI:

1. **Rótulos por biópsia.** Como a comparação primária roda na validação cruzada interna do dataset de treino, a qualidade do rótulo *do treino* determina diretamente a qualidade do resultado principal.
2. **Split por paciente é real.** As partições oficiais resolvem o problema de vazamento e ainda dão comparabilidade com a literatura de graça. Não invente folds próprios.
3. **~3× mais dados.** Isso desarma o principal confundidor da H2 (transformers são famintos por dados; com 647 imagens, um ViT poderia ir mal pelo motivo errado).

Teste externo — BUSI

- 437 benignas × 210 malignas
- **Classe normal descartada.** Sem lesão → máscara vazia → a operação de masking fica indefinida (no hard masking, a imagem inteira viraria preta, criando

- um atalho trivial). Justificar em uma frase no artigo.
- Treinar no BUS-BRA, testar no BUSI **sem re-treino**.

Nota agradável: como o BUSI vira conjunto de teste puro, o conhecido problema de duplicatas dele deixa de ser vazamento — nada atravessa a fronteira treino/teste. Ainda vale deduplicar (duplicatas reduzem o n efetivo e correlacionam erros, o que estraga o intervalo de confiança), mas o risco grave desapareceu.

Extra opcional — UDIAT / Dataset B

163 imagens, benchmark externo clássico. **Só se sobrar tempo.** BUS-BRA (treino) + BUSI (teste externo) já é suficiente para um congresso de IA: há validação cross-dataset, cross-scanner e cross-país. Um terceiro dataset agrega pouco perto do custo.

4. Design experimental

Uma equação organiza tudo

Toda condição é a mesma operação, mudando apenas o mapa de pesos:

$$I' = W \cdot I + (1 - W) \cdot B$$

- I = imagem original
- M = máscara binária da lesão
- W = mapa de pesos, construído a partir de M
- B = fundo substituto

Fator A — Perfil de atenuação

Condição	O que acontece fora da lesão	O que remove
full	nada muda	— (baseline)
hard	zera	tudo
scalar-0.5	multiplica por 0,5	contraste
scalar-0.3	multiplica por 0,3	contraste
blur	substitui pela versão borrada da própria imagem	textura (alta frequência)
dist-EDT	escurece progressivamente com a distância à borda	informação distante

Dois pontos que devem aparecer explicitamente no artigo:

Hard masking é a atenuação escalar com $c = 0$. Não são dois experimentos separados — é um eixo contínuo, e o hard é a extremidade dele. Isso deixa o design elegante e rende um gráfico bom (AUC $\times$ intensidade de atenuação).

Os três "soft" não são o mesmo efeito em doses diferentes. Cada um remove uma coisa distinta: o escalar mexe no **contraste** (preserva integralmente a estrutura espacial), o blur mata a **textura**, a transformada de distância impõe um **prior de proximidade**. É isso que mostra que a escolha dos métodos foi pensada, e não sorteada.

Fator B — Raio da margem

$r \in \{0, 10, 25\}$ px — dilatação morfológica de M antes de aplicar o perfil. Calibrar os valores ao tamanho típico de lesão no BUS-BRA.

Grade

6 perfis $\times$ 3 raios $\approx$ 16 células úteis (full não tem raio), $\times$ 2 modelos $\times$ 5 folds $\times$ 3 seeds.

5. Modelos

Modelo	Papel
ResNet-50 (pré-treinada)	CNN — braço principal, onde roda a comparação confirmatória

Swin-T ou ViT-S/DeiT-S (pré-treinado) Modelo	Transformer — testa a H2 Papel
---	-----------------------------------

Cortes e justificativas

YOLOv8-cls — cortar. É um CNN (backbone CSPDarknet), não uma terceira família arquitetural. Redundante com a ResNet-50.

DETR — vira resultado adicional, não braço principal. Ele de fato classifica (emite classe por query) — isso está correto. O problema é outro: **com hard masking, a lesão é literalmente "onde há pixel não-preto"**, então a detecção fica trivial. Conforme a atenuação aumenta, a tarefa de localização fica *mais fácil* enquanto o contexto de classificação é *removido* — dois efeitos opostos misturados na mesma métrica, impossíveis de separar. Some-se a isso que as bounding boxes de treino derivam da própria máscara GT (mais dependência de oráculo) e que a regra de agregação query → classe vira um hiperparâmetro escondido.

6. Pipeline de pré-processamento

A ordem das operações é onde os bugs moram.

```
carregar I e M
↓
augmentation GEOMÉTRICA → aplicada IDENTICAMENTE a I e M (mesmo seed)
↓
construir W a partir de M (dilatar por r → aplicar perfil de atenuação)
↓
compor I' = W·I + (1-W)·B
↓
augmentation fotométrica (opcional)
↓
resize 224×224 ← canvas e posição FIXOS em todas as condições
↓
normalizar → rede
```

Quatro armadilhas

- Augmentation geométrica precisa ser aplicada à imagem e à máscara juntas.** Se a máscara desalinhar, o modelo aprende ruído. É o bug mais comum deste tipo de pipeline.
- O blur vai na imagem original, antes da composição.** Se você borrar a imagem já mascarada, os pixels pretos do fundo vazam para dentro da lesão e criam um halo escuro na borda — um artefato que a rede vai aprender.
- Feathering de 1–2 px na borda do hard mask.** Um recorte binário desenha um contorno perfeito e nítido com o formato exato da lesão. A rede pode classificar lendo **apenas esse contorno**, sem olhar o conteúdo. Isso é um confundidor *a favor* do hard masking — ou seja, jogaria contra a H1 pelo motivo errado.
- Canvas fixo.** Se recortar a lesão e redimensionar, a escala aparente do nódulo muda entre condições — e você passa a medir *resize*, não *masking*.

Antes de treinar qualquer coisa: salve um grid de exemplos de cada célula da grade e **olhe com os próprios olhos**. Meia hora que evita duas semanas perdidas.

7. Controles

Baratos, e desproporcionalmente valiosos.

Controle	O que responde
Context-only — apaga a <i>lesão</i> , mantém o entorno	Quanta informação vive fora da lesão? Testa a H1 pelo avesso. Se ficar bem acima do acaso, é a figura mais forte do artigo.
Máscara deslocada aleatoriamente	O ganho vem da localização correta, ou apenas de "ter menos coisa na imagem"?
Teste de atalho — classificar usando só bordas, dimensões e marcações do aparelho	Se der acima do acaso, o dataset tem viés espúrio e tudo precisa ser reinterpretado. Em ultrassom clínico, calipers e anotações são um risco real (se aparecerem mais em malignos, o modelo acerta sem olhar a lesão). Rodar na Semana 1.

8. Protocolo estatístico

- 5 folds oficiais × 3 seeds** por célula. Um run único não vale nada — a variância entre seeds costuma engolir o efeito medido.
- AUC-ROC** como métrica primária, com **IC95%**. Secundárias: sensibilidade, especificidade, F1, balanced accuracy. Acurácia sozinha é inútil com

desbalanceamento ~2:1.

- **Comparação primária:** teste pareado nos mesmos folds (Wilcoxon pareado).
- **Comparações secundárias:** correção de Holm–Bonferroni.
- Declarar no texto, sem ambiguidade, o que é **confirmatório** e o que é **exploratório**.
- Class weights na loss ou amostragem balanceada — fixar a escolha a priori, não testar as duas e ficar com a melhor.

9. A questão do oráculo

Isto precisa estar escrito no artigo. É o único ponto que causa rejeição sumária se ficar implícito.

O que é

A operação de masking exige a máscara da lesão. No treino, isso é normal. No **teste**, se a máscara vier do ground truth do dataset, o modelo recebe, no momento da inferência, informação que um sistema real jamais teria: alguém já localizou e delineou a lesão para ele. Isso se chama **configuração oráculo** (*oracle segmentation*).

Por que não invalida o trabalho

A pergunta aqui é **científica, não clínica**. Não se está propondo um produto — está-se perguntando *quanta informação diagnóstica existe fora da lesão*. Para isolar isso, é **necessário** ter uma máscara perfeita; caso contrário, o erro de segmentação se mistura ao efeito que se quer medir.

O que torna isso aceitável: dizer

No abstract e na seção de método:

Todos os experimentos utilizam segmentação ground-truth também em tempo de inferência (configuração oráculo). Portanto, os resultados quantificam o valor informacional do contexto peri-lesional sob segmentação ideal, e não o desempenho de um sistema implantável.

Escopo declarado, revisor aceita. Escopo escondido, revisor rejeita. É só isso.

Em aberto — segmentador automático

Fica como item condicional, a decidir conforme o andamento:

- **Opção A (padrão):** apenas oráculo, com a declaração acima. Artigo completo e honesto.
- **Opção B (se houver tempo — é o que mais valoriza o trabalho):** treinar uma **U-Net** apenas nos folds de treino, gerar máscaras preditas para o teste, e reportar a tabela de degradação:

Condição	AUC (máscara oráculo)	AUC (máscara predita)	Δ
Hard masking	...	...	...
Melhor soft masking	...	...	...

Hipótese: o soft masking deve ser **mais robusto a erro de segmentação**, porque um contorno errado num hard mask apaga tecido real (ou insere fundo), enquanto num soft mask apenas atenua um pouco a mais ou a menos. Se confirmar, vira um argumento **prático** a favor do soft masking — não apenas informacional. É bônus, não requisito.

10. Análise bônus (custo: zero runs adicionais)

O BUS-BRA fornece **BI-RADS 2–5**. Basta fatiar as predições do conjunto de teste e verificar **em qual categoria o masking mais importa**.

Predição específica e falsificável: o contexto peri-lesional deve pesar mais nos casos **ambíguos (BI-RADS 4)** do que nos extremos (2 = claramente benigno, 5 = claramente maligno). É exatamente no BI-RADS 4 que a decisão de biópsia é difícil e onde os sinais acústicos secundários (sombra posterior, reforço, halo) entram de fato na leitura do radiologista.

Uma tarde de análise, e rende discussão clínica de verdade.

11. Cronograma

Semana 1 — Infraestrutura. Zero resultados.

- Carregar as partições oficiais do BUS-BRA
- Implementar o pipeline de masking com **todos** os perfis
- **Validação visual** de um grid de exemplos de cada célula
- **Teste de atalho** (calipers, anotações, dimensões)
- Baseline `full` rodando ponta a ponta na ResNet-50

O protocolo é **CONGELADO** no fim da Semana 1. Métrica, splits e grade não mudam depois disso.

Semana 2 — Grade completa na ResNet-50

Perfis × raios, 3 seeds. Primeiras tabelas e o gráfico AUC × intensidade de atenuação.

Semana 3 — Transformer, estatística, escrita

Swin-T / ViT-S na grade. Testes pareados. **Começar a escrever agora**, não na Semana 4.

Semana 4 — Teste externo e fechamento

BUSI. Controles. Figuras, limitações, revisão. (UDIAT e U-Net só se sobrar folga real.)

12. O que cortar

- YOLOv8-cls — redundante com a ResNet-50
- DETR como braço principal — vira resultado adicional
- Multi-stream (full + crop + crop+context) — é um segundo artigo
- ⚠ Verificar se o "estudo recente" citado no plano original existe de fato. Modelos de linguagem alucinam referências com frequência, e uma citação falsa em submissão é um problema sério.

13. Trabalho futuro (para a seção de Future Work)

Anisotropia direcional da margem

A física do ultrassom prediz que o contexto **posterior** à lesão (sombra ou reforço acústico) carrega mais informação diagnóstica que o contexto lateral ou anterior. Isso é testável dilatando a máscara de forma **assimétrica** — só para baixo, só lateralmente — e comparando o ganho de cada direção.

Por que fica de fora agora: (a) o cronograma de um mês não comporta; (b) a justificativa exige cuidado — a orientação anatômica da imagem precisa ser verificada caso a caso, e a profundidade da sombra depende da geometria e do ganho do aparelho, o que introduz confundidores que exigiriam controle adicional.

Mas é a continuação natural e mais interessante do trabalho, e vale sinalizar no artigo.

Outras direções

- Máscara como **4º canal de entrada** ou como supervisão auxiliar na loss, em vez de composição na imagem
- Validação externa ampliada (UDIAT, BrEaST, STU-Hospital)
- Pipeline end-to-end com segmentação automática (Opção B acima, promovida a contribuição principal)

14. Expectativa

Um estudo **controlado**, com hipótese declarada a priori, split por paciente real, rótulos por biópsia, validação cross-dataset e escopo (oráculo) honestamente delimitado é substancialmente mais publicável do que uma grade de 80 runs sem pergunta.

E vale registrar: **um resultado negativo publica**. Se o soft masking não superar o hard masking — ou se o contexto não agregar nada —, isso continua sendo informação útil para a comunidade, desde que o desenho seja limpo o bastante para que o leitor acredite no "não".